DOI: 10.3969/j.issn.0255-8297.2026.05.001

融合大语言模型的区块链开源项目主题挖掘与演化分析

饶芮瑞， 朱 莉， 颜嘉麒
南京大学 信息管理学院，江苏 南京 210023

摘 要： 本文基于2021—2024年GitHub区块链开源项目，提出融合大语言模型与BERTopic（bidirectional encoder representations for topic）模型的开源项目主题识别框架：依据大语言模型提示词工程对开源项目进行特定数据预处理与文本精炼，并通过词嵌入、降维UMAP（uniform manifold approximation and projection）以及基于层次密度的空间聚类算法（带噪声）构建BERTopic模型以实现区块链主题识别，然后采用结合“大语言模型主题表示和命名”以及“专家评判与优化”的方式生成区块链开源项目主题标签。在得到主题识别结果的基础上，构建“主题强度-技术影响力-再创活跃度”三维指标体系进行主题评价和技术主题演化特征分析。研究表明，区块链开源生态呈现出“基础巩固- 应用扩展-智能融合”的演化路径。除了识别出围绕智能合约、去中心化金融、非同质化代币等方面展开的常见技术主题外，还发现“AI+区块链”相关技术主题正成为新的增长点。多维指标评估显示，开发者社区在追随技术和市场热点的同时，持续夯实安全基础与工具链建设。

关键词： 区块链；主题挖掘；主题演化；开源项目；GitHub；大语言模型
中图分类号： TP391 **文章编号：** 0255-8297(2026)05-0701-15

Topic Mining and Evolution Analysis of Blockchain Open-Source Projects Integrating Large Language Model

RAO Ruirui, ZHU Li, YAN Jiaqi
School of Information Management, Nanjing University, Nanjing 210023, Jiangsu, China

Abstract: Based on GitHub blockchain open-source projects from 2021 to 2024, this paper proposed a topic identification framework for open-source projects that integrates a large language model with bidirectional encoder representations for topic (BERTopic). The framework first applied large language model prompt engineering to perform specific data preprocessing and text refinement for open-source projects. It then constructed a BERTopic model through word embedding, dimensionality reduction using uniform manifold approximation and projection (UMAP), and hierarchical density-based spatial clustering of applications with noise (HDBSCAN) to identify blockchain topics. Finally, topic

收稿日期： 2026-02-23
通信作者： 颜嘉麒，教授，研究方向为区块链、信息系统、数据分析、情报学。E-mail: jiaqiyan@nju.edu.cn

中国知网 https://www.cnki.net

labels for blockchain open-source projects were generated by combining "topic representation and naming using a large language model" with "expert evaluation and optimization". Based on the topic identification results, a three-dimensional index system comprising "topic intensity-technological influence-secondary development activity" was constructed to evaluate the identified topics and analyze their evolutionary characteristics. The research shows that the blockchain open-source ecosystem presents an evolutionary path of "foundation consolidation-application expansion-intelligent integration". In addition to identifying common technical topics around smart contracts, decentralized finance (DeFi), non-fungible tokens (NFTs), etc., the study also finds that "AI + blockchain"-related technical topics are becoming new growth points. The multidimensional index evaluation shows that the developer community continues to strengthen security foundations and toolchain development while keeping pace with technological and market trends.

Keywords: blockchain, topic mining, topic evolution, open-source projects, GitHub, large language model

区块链技术作为 21 世纪最具革命性的数字创新之一，正以前所未有的速度和广度重塑全球产业格局。从 2008 年 Nakamoto [1] 首次提出区块链以来，区块链这种不可篡改、去中心化、高安全性的分布式账本技术已经从最初的加密货币应用迅速扩展到金融、医疗、供应链、政务、能源等诸多领域 [2]，并展现出强大的技术延展性与产业赋能潜力。随着以人工智能、元宇宙为代表的颠覆性技术的快速发展，与区块链技术相关的基础设施建设和融合应用也正在被深刻地改变 [3]。区块链技术开放协同的技术理念与开源开发模式高度契合，使得以 GitHub 为代表的开源平台成为区块链技术创新、项目孵化和开发者社区协作的核心载体 [4]。因此，从技术视角依据主题识别方法研究区块链技术开源项目的主题分布与动态演化规律，对把握区块链技术前沿、洞察社区研发焦点、推进学术研究具有重要意义。

然而，当前研究仍存在一定局限性：首先，数据选择单一化和研究维度碎片化特征明显。现有研究多聚焦于区块链学术文献与专利数据的主题探索 [5]，但这类数据在区块链技术实时发展方面存在一定滞后性 [6]，难以实时捕捉到区块链技术快速迭代与动态演进的实际情况。尽管已有学者尝试基于开源项目进行区块链技术主题挖掘，但这些研究仍局限于区块链某一具体平台或应用场景 [7]，尚缺乏从整体视角分析区块链技术在开源项目中的关注重点与主题演化情况 [8]。其次，现有主题研究方法仍存在不足，导致主题识别效度不高。基于传统科学计量的识别方法 [9] 对文本语义挖掘不够充分，忽略了语言表达的复杂性以及现实需求性。为提取更多未知、潜在的信息，基于文本挖掘的主题识别方法 [10] 以及以 BERTopic 模型为代表的神经主题建模方法 [11] 也逐渐被应用于主题识别研究中，但这些方法在处理短文本、稀疏数据时存在局限，难以充分捕捉文本复杂的潜在语义 [12]，在主题识别方面仍存在辨识度不高、稳定性不强以及语义表达能力不足的问题 [11,13]。因此，进一步丰富研究数据类型，并依赖最新先进技术优化主题识别方法以提升识别效果是亟需解决的问题。

近年来，大语言模型（large language model, LLM）的迅猛发展极大地改变了自然语言处理的范式。这些模型凭借海量参数和训练数据，展现出强大的语言理解和生成能力 [14]，为主题识别的根本性变革带来了新的契机。与传统主题识别方法相比，大语言模型在上下文理解和知识整合方面具有优势，且相关研究证明将其应用于主题识别任务的文本嵌入 [15]、主题发现 [16] 等阶段都有着良好的表现。因此，整合传统主题研究方法和大语言模型的优势进行主题识别，将有利于提取到更精准的语义信息、挖掘到更细粒度并具有解释力的主题 [17]，以帮助决策者从海量文本中快速获取有价值的见解 [13]。

中国知网 https://www.cnki.net

综上所述，考虑到 GitHub 项目的“自述文档”（readme）是开发者对技术栈、功能定位与应用场景的凝练 [18]，本文以 2021—2024 年 GitHub 区块链开源项目 readme 文档为研究对象以丰富区块链领域主题识别数据源。鉴于 BERTopic 模型在主题识别任务中的局限性，本文引入 LLM 将其与 BERTopic 模型结合，以优化 GitHub 数据预处理和主题识别的效率与质量，并构建“主题强度-技术影响力-再创活跃度”三维指标体系进行主题评价和技术主题演化特征分析。在理论层面，本文丰富了区块链技术主题识别的数据源维度，验证了“LLM+BERTopic”方法在非结构化开源文本中的适用性，为技术演化研究提供了新的方法论范式。在实践层面，利用 GitHub 开源社区中“关注度”（star）、“分支量”（fork）等社区行为数据，将其量化为主题强度、技术影响力与再创活跃度 3 项指标，以此揭示区块链技术生态的动态演化，为开发者和学术研究者把握区块链技术动向提供重要参考。

1　主题识别与演化分析框架

本文主题识别和分析框架如图 1 所示。首先，通过调用 GitHub API 的方式从 GitHub 平台爬取区块链领域 2021—2024 年的开源项目数据。其次，基于大语言模型和提示词工程对开源项目中的 readme 文档进行常规文本预处理操作和 GitHub 文本特定预处理操作，形成主题识别语料库。然后，基于 BERTopic 模型对已预处理的语料进行主题挖掘，得到“文档-主题分布”和“主题-词分布”等信息，并采用“大语言模型主题表示和命名”以及“专家评判与优化”的方式进行主题命名。最后，基于 2021—2024 年的区块链开源项目主题信息，按年份进行时间窗口划分，通过相似度计算以及技术主题多维评价指标构建，完成相邻时间窗口主题演化分析和区块链 GitHub 主题分析。

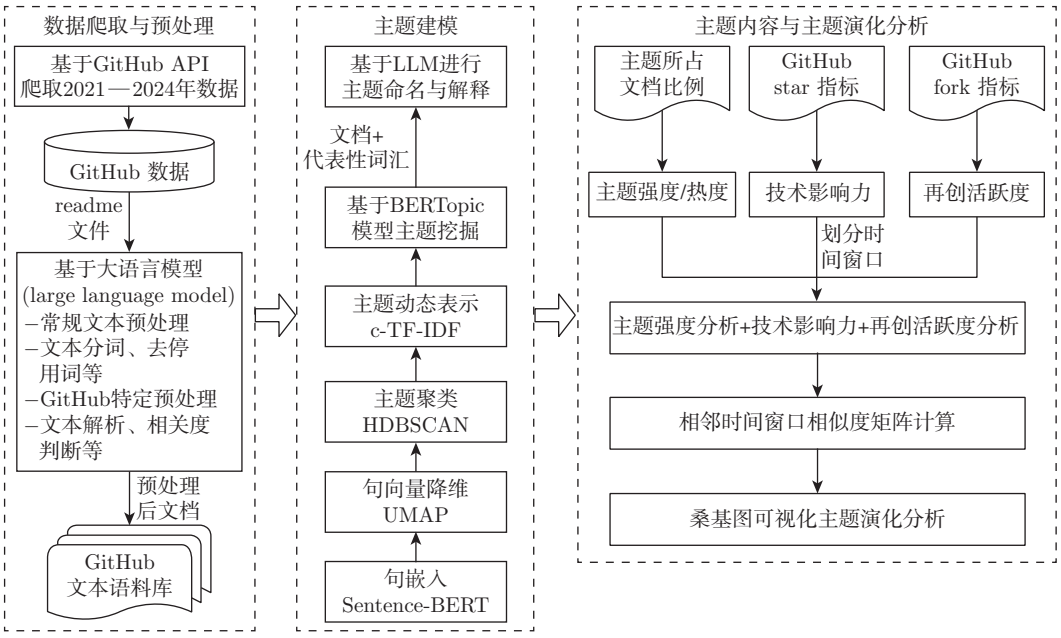


图 1　研究设计流程图

Figure 1　Research design flowchart

1.1　融合大语言模型的数据预处理

相较于学术论文和专利数据严格的格式规范和表达规范，GitHub 的 readme 文件，即项

中国知网　https://www.cnki.net

目“自述文档”，在表达和内容上存在非标准化的情况。常混合技术说明、安装指南、代码片段、链接、表情符号等与项目实际主题相关度较低的噪声数据。因此，除了常规的主题识别任务文本预处理操作以外，包括分词、去停用词、词形还原等，还需要针对 GitHub 文本特点进行特定的数据处理，包括解析 Markdown 结构以提取主要文本块、清洗文本（去除 URL、图片链接、代码块等）、去除与项目主题无关的表述、剔除对主题挖掘贡献意义较低的项目等（例如只有简单技术说明的项目或字数很少的项目等）。

针对 readme 文档的上述特性，本文基于大语言模型提示词工程对 GitHub 的 readme 进行文本精炼，即在不改变文本结构与原意的前提下提取能够代表项目核心内容的文本内容。其优势主要体现在以下方面：1）格式解析能力，自动识别判断 Markdown 格式、代码块、链接等非结构化元素；2）语义理解优势，大模型具备良好的语义理解能力，能够准确识别并保留与项目核心功能相关的关键表述；3）上下文感知能力，在处理多层级标题结构时，可依据语义关联性判断章节重要性，优先保留如“Introduction”“Usage”等有意义的部分；4）处理效率，相比传统正则表达式或规则库，大模型能一次性处理多类型噪声，且通过上下文学习能一定程度上避免误删有效信息。

因此，本文根据数据处理任务构建了基于大语言模型与指令工程的 GitHub 文本自动预处理方法。具体原则与步骤如下：

步骤 1 指定大模型角色：设置为“区块链领域 GitHub 开源项目文本分析师”，限定其领域知识范围；

步骤 2 设置提示指令：告知大模型需进行的任务、需处理的文本内容以及指定结果的输出格式；

步骤 3 示例引导：提供 20 篇人工处理示例，以规范模型须遵循的风格、逻辑和规范；

步骤 4 指令微调：抽取 100 篇 GitHub 文本内容进行指令处理效果测试，根据处理结果和区块链专家判定调整提示指令；

步骤 5 分批次处理：为应对大模型幻觉和上下文遗忘等问题，每次只处理 50 篇文本。

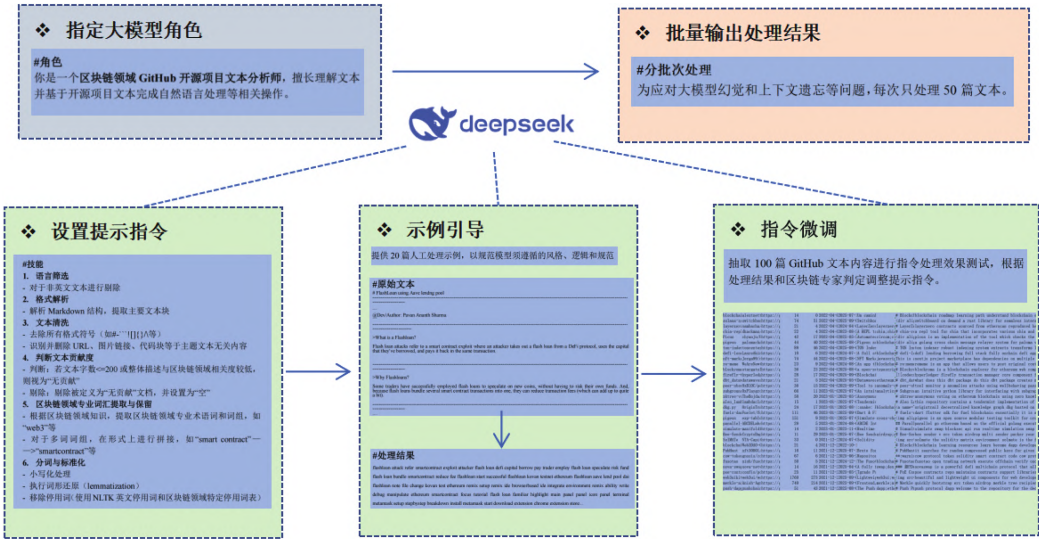


图 2 提示词设计原则与步骤

Figure 2 Prompt design principles and steps

中国知网 https://www.cnki.net

1.2　基于 BERTopic 的主题挖掘

本文采用 BERTopic 模型进行主题挖掘，BERTopic 是由文献 [11] 提出的一种动态主题模型，其基于预训练模型按照文本嵌入、嵌入降维及向量聚类、主题表示等步骤进行主题挖掘任务。

首先，构建文本嵌入。本文采用 Sentence-BERT 的“MiniLM-L12-v2”模型进行文本嵌入构建。该模型基于 MiniLM 架构优化，在保持低计算开销的同时能够有效捕获文本语义信息，并保证语义相似的文本在向量空间中接近 [19]。将数据预处理后的 readme 文本语料作为模型输入，进行文本嵌入，得到句向量。然后，进行嵌入降维及向量聚类。为了更好地保留全局语义特征并保证后续的聚类质量，在嵌入阶段采用 UMAP （uniform manifold approximation and projection）算法进行降维。接着，对降维后的基于层次密度的空间聚类算法（带噪声）（hierarchical density-based spatial clustering of applications with noise, HDBSCAN）进行主题聚类。该算法能自动识别并剔除噪声点，以此形成具有语义凝聚性的主题簇 [20]。其主题数量通过模型参数动态确定，基于密度阈值实现自适应的主题划分。最后，进行研究主题挖掘与表征。基于聚类形成的句向量类团，采用基于类的词频-逆文档频率（class-based term frequency-inverse document frequency, c-TF-IDF）算法进行主题表征。该算法在传统词频-逆文档频率（term frequency-inverse document frequency, TF-IDF）基础上改进，通过计算词项在特定主题类团中的权重，提取每个主题的代表性词汇 [21]。其中，BERTopic 模型关键参数的设定，包括“min_topic_size”“n_neighbors”等，先参考原始论文中设定的默认值进行初步设置 [11]，再根据区块链技术主题实际挖掘效果进行多轮参数实验调优以确定最后结果。

1.3　融合大语言模型的主题表示

主题表示是指对主题挖掘所获得的代表词列表进行主题命名和含义解释，并根据这些结果将文本数据中隐藏的主题揭示出来 [22]。然而，从单个词语列表中推导出一个能够准确描述术语列表所隐含的主题的命名，有着较大的难度。一方面，初始提取的关于主题的词语列表本身包含的语义信息就不够丰富，且不同主题间的词语还存在经常重复、语义差别细微的情况，因此高质量完成主题解释会存在一定困难。另一方面，从主题抽取所获得的术语列表中凝练出一个较为贴切的主题需要大量的专业知识和经验，且领域专家进行主题命名和解释时也易受到其知识全面性和主观性的影响。

为了应对上述问题，本文采用“大语言模型主题表示和命名”以及“专家评判与优化”的方式进行主题表示，以期降低主题解释的时间和资源需求，并获得更高质量、客观准确的主题命名和主题解释。具体步骤可概括为：

步骤 1　主题检查：首先利用 LLM 检查每个由 BERTopic 获得的主题单词列表，了解各个主题的大概含义；

步骤 2　确定中心主题：LLM 筛选已获得的词语列表，根据大模型提示工程进行主题命名，并且为了规避代表词汇能力有限、静态主题解释力不足的问题 [23]，在 LLM 初步判断了首次主题后，会通过交互的方式继续与 LLM 对话，以更新主题代表词汇顺序和主题解释内容；

步骤 3　判定主题准确性和质量：由 6 位具备区块链领域知识和自然语言处理经验的专家对所得结果进行人工检验，若每个主题的通过率超过 80%（即 5 人认可结果），即认定结果为合理，否则为不合理，对于不合理结果将进行人工重新命名或剔除。

1.4　技术主题评价指标

对于开源项目主题评价，目前尚未形成公认的技术主题评价指标。本文参考已有研究，探索基于论文以及专利数据的主题热度、主题影响力等指标设定规则 [24]，并结合 GitHub 开源

中国知网　https://www.cnki.net

项目已有数据标签特性，如 star（点赞/收藏数）、fork（分支量）等，综合考虑指标的可解释性和实践性，最终创建主题强度、技术影响力、再创活跃度 3 项指标来评价 GitHub 技术主题。

主题强度是指某个时间段内主题在文档集合中所占的比例

$$I_i = \frac{n_i}{N_j} \tag{1}$$

式中：I_i 为第 i 个主题的主题强度；n_i 为第 i 个主题的文献数量；N_j 为第 j 个时间段的文献总量。

技术影响力是衡量某个技术主题受关注和认可程度的重要指标。本文选用 GitHub 中每个项目的 star 数作为衡量技术影响力的指标。其中，开发者“star”的这个行为有两层含义：一方面，它作为一个收藏记录键，让开发人员跟踪他们感兴趣的项目；另一方面，它代表着开发人员对该项目的关注与喜爱 [25]。为了更精准地反映某一主题下绝大部分开源项目的实际影响力与关注度，本文进行了以下处理：1）剔除极端值，在各主题的 star 基本符合正态分布的情况下，对两端各 5% 项目进行修剪（共 10%）；2）计算剔除极端值后 star 的均值，并将其作为衡量技术影响力的指标。

$$T_i = \frac{1}{m_i}\sum_{k=1}^{m_i} \mathrm{star}_k^{\mathrm{trim}} \tag{2}$$

式中：T_i 为第 i 个主题的技术影响力；$\mathrm{star}_k^{\mathrm{trim}}$ 为第 i 个主题下第 k 个项目经极端值修剪后的 star 数；m_i 为第 i 个主题经修剪后保留的项目数量。

再创活跃度是衡量项目活力和社区健康度的重要指标，本文选用 GitHub 中的“fork”作为计算指标。有研究指出，fork 行为是后续技术协作和贡献的起点，其代表着实质性的开发参与度和项目生态的扩展度 [26]。与技术影响力计算过程相似，首先进行剔除极端值和均值计算操作，以获得更高质量、更具有解释意义的评价指标。值得一提的是，本文发现 fork 数值与 star 数值常存在正相关关系，若只是单一地将 fork 数作为再创活跃度的衡量指标，那么该指标的解释力将不够全面和严谨。因此本文将主题的 fork 均值与 star 均值之商作为衡量再创活跃度的指标。

$$R_i = \frac{\frac{1}{m_i}\sum\limits_{k=1}^{m_i} \mathrm{star}_k^{\mathrm{trim}}}{\frac{1}{m_i}\sum\limits_{k=1}^{m_i} \mathrm{fork}_k^{\mathrm{trim}}} \tag{3}$$

式中：R_i 为第 i 个主题的再创活跃度；$\mathrm{star}_k^{\mathrm{trim}}$ 为第 i 个主题下第 k 个项目经极端值修剪后的 star 数；$\mathrm{fork}_k^{\mathrm{trim}}$ 为第 i 个主题下第 k 个项目经极端值修剪后的 fork 数；m_i 为第 i 个主题经修剪后保留的项目数量。

1.5 主题演化分析

随着区块链技术发展与产业应用的日益紧密联系，挖掘区块链开源项目主题演化规律对了解区块链技术生态、预测技术发展具有重要的价值。因此，本文基于主题挖掘结果，从动态演化视角追踪各主题在不同时间段的关注度变化和相似主题的演化规律。具体步骤包括：1）将数据集按年份划分为 4 个时间窗口，构建相邻时间窗口；2）计算不同时间窗口下的主题相似度，识别主题间跨时段关联关系；3）进行桑基图可视化，系统分析 2021—2024 年区块链技术主题的动态演化规律。

中国知网 https://www.cnki.net

对于主题相似度，本文使用余弦相似度来度量两个向量之间的相似度 [27]。

$$\cos\theta = \frac{a \cdot b}{|a| \times |b|}, \quad \cos\theta = [-1, 1] \tag{4}$$

式中：a 和 b 为高维向量，余弦相似度越接近 0，则表示主题之间越不相似。对于桑基图，各年主题按照“年份-主题 ID”格式标注，并基于相似度阈值建立各主题间的链接。其中，前一年主题与后一年主题之间的链接宽度与相似度值呈正相关。结合相似度矩阵与桑基图结果，并参考已有研究的分类标准 [28]，重点挖掘三类区块链技术主题演化模式：主题延续型、主题分裂和主题融合型、新兴主题和衰退主题。延续型主题指主题间相似度不小于 0.5，有着技术持续发展的特征；主题分裂和主题融合指的是单一主题发展为多个新主题或多个主题汇聚为一个主题，揭示了技术细分或融合的趋势；新兴主题和衰退主题主要关注单个主题的路径发展，无后向链接的主题视为衰退，无前向链接的主题视为新兴。

2　实验设置

2.1　数据采集与预处理

本文以 2021—2024 年 GitHub 平台区块链领域 readme 文档为分析对象，按照“GitHub 平台检索-调用 API 爬取开源项目-大模型预处理”的步骤进行数据采集和数据预处理。

首先，确定检索字段为“blockchain OR bitcoin OR cryptocurrenc* OR ethereum OR smart contract”。考虑到在 GitHub 中“star”数常作为衡量一个项目质量高低的重要指标之一，为了保证所爬取数据的质量，本文在检索时将“star>=10”设置为限制条件 [29]。并导出每个仓库项目的关键信息，包括“项目名称（full name）”、“项目简短描述（description）”、“项目自述文件（readme）”、“项目创建时间（date created）”、“项目点赞收藏数（number of stars）”、“项目分支量（number of forks）”，最终得到 10 410 个仓库项目。

然后，基于 DeepSeek-V3 推理速度快且性能优异的优势以及大模型在主题识别、文本处理方面的优异表现 [13]，本文以 DeepSeek-V3 为基座，设计提示词工程进行数据预处理。大模型主要完成两大类预处理任务：文本挖掘常规预处理和 GitHub 文本特定预处理。其中 GitHub 文本特定预处理包括：1）语言筛选，目标处理文本语言为英语，对非英文文本进行剔除；2）剔除 readme 文档中字数小于 200 的项目和区块链领域相关度较低的文档，这类自述文件所蕴含的信息量过少，不能很好地支持后续主题挖掘任务；3）剔除无关文本，GitHub 中有些项目的 readme 文件常只包含技术实现细节、维护日志、贡献指南等对主题无直接贡献意义的外围内容；4）格式解析，解析 Markdown 结构，去除代码块、链接等非结构化元素，提取主要文本块，自动去除无关内容；5）文本清洗，移除所有标点符号、格式符号、数字。具体提示词设计如图 3 所示。

最终，经过数据预处理后得到 6 839 个仓库项目。其中，2021 年为 2 237 个，2022 年为 2 137 个，2023 年为 1 522 个，2024 年为 943 个。

2.2　主题建模

按照 1.2 节提及的 3 个主要步骤，即文本嵌入、嵌入降维及向量聚类、主题表示，基于 BERTopic 模型进行主题挖掘，并采用“人工+大模型”的方式进行主题表示。由于各年份的 readme 文档数量充足，故本文按照年份依次对预处理后的仓库项目进行了 4 次主题建模。通过多次实验优化参数，最终参数为“top_n_words=30”、“min_topic_size=8”、“n_neighbors=10”。其中有些仓库项目会被标记为噪声数据，针对此类项目，本文采用人工判读和大模型辅助的方式，重新划分此类项目主题。若仍未找到符合要求的主题标签，则进行剔除。

中国知网　https://www.cnki.net

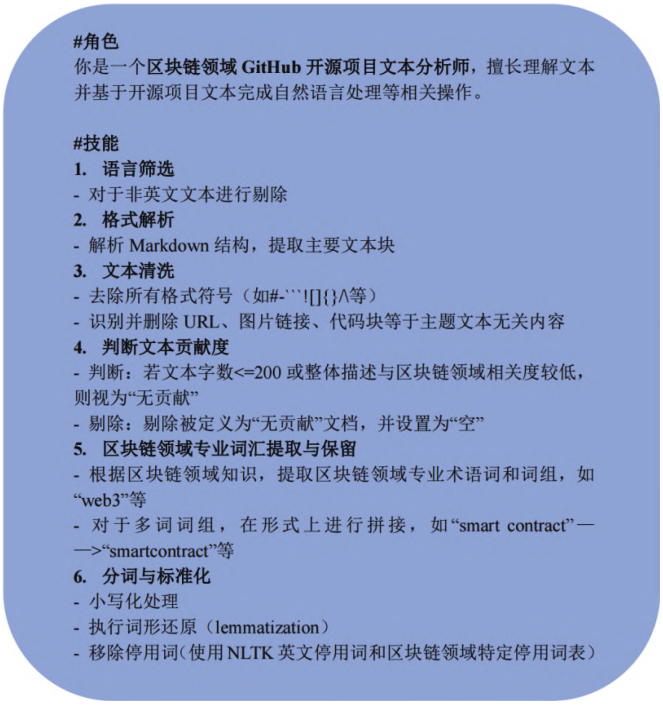


图 3 提示词核心部分设计

Figure 3 Core components of prompt design

根据“大语言模型+BERTopic”开源项目主题识别框架，最终挖掘结果为 2021 年 14 个主题，2022 年 15 个主题，2023 年 16 个主题，2024 年 13 个主题。将各年份主题挖掘得到的“主题-词分布”结果依次作为大模型输入，让大模型根据提示词进行主题命名，并给出相应的解释。在大模型完成主题命名和解释后，让 6 位区块链领域专家根据大模型给出的主题命名结果并参考实际文档内容进行质量评价，得到最终主题标签。2021—2024 年部分主题挖掘结果如表 1 所示。

3 主题分析

将 2021—2024 年划分为 4 个时间窗口，并基于主题挖掘结果，从主题内容和时间两个维度对区块链领域 GitHub 主题进行技术主题分析和动态主题演化分析。

3.1 技术主题分析

3.1.1 主题强度分析

在主题强度方面，以各时间窗口下主题在文档集合中所占的比例为衡量指标，各年份的主题强度可视化结果如图 4 所示。

2021 年，主题强度最高的主题是“DeFi 基础设施”和“NFT 与数字艺术市场”，分别占比 23.9% 和 11.5%。这一特征与该年技术发展情况基本吻合。作为去中心化金融的核心载体，DeFi 基础设施的完善性和可扩展性会直接影响到整个生态的运行情况，因此其是技术开发者重点关注的部分。与此同时，NFT 技术凭借数字艺术品的出圈在开发者社区获得广泛关注。以“larvalabs/cryptopunksmarket”项目为例，其将艺术品所有权与链上数据绑定，为数字内容的确权与流通提供了范式参考。

中国知网 https://www.cnki.net

表 1　区块链开源项目主题挖掘结果（2021—2024，部分）

Table 1　Topic mining results of blockchain open-source projects (2021—2024, partial)

年	序号	主题标签	主题词（部分）
2021	0	Solana 生态开发	Solana; docker; command; install; build
	1	智能合约应用与租赁	rental; smartcontract; payment; fee; owner
	2	DeFi 基础设施	DeFi; build; smartcontract; decentralize; user
	3	NFT 与数字艺术市场	NFT; mint; art; contract; file
	7	比特币协议与钱包安全	bitcoin; key; wallet; address; private
2022	0	智能合约应用与租赁	contract; rental; smartcontract; bike; deposit
	1	DApp 开发与 DeFi	build; decentralize; DeFi; smartcontract; repository
	4	NFT 创建与市场	NFT; mint; market; metadata; image
	10	闪电贷与 DeFi 借贷	flash; loan; flashloan; borrow; arbitrage
	14	智能合约安全与漏洞检测	vulnerability; dataset; smartcontract; detect; solmate
2023	0	零知识证明与智能合约	contract; ZK; alliance; test; smartcontract
	1	比特币钱包与支付安全	bitcoin; wallet; key; lightning; payment
	8	AI+ 智能合约	AI; smartcontract; scheme; trader; agent
	9	加密货币预测模型	model; data; outcome; prediction; forecast
	12	区块链+医疗健康	record; product; medical; certificate; health
2024	0	区块链开发与智能代理	contract; data; bitcoin; test; agent
	1	加密钱包技术与安全	wallet; key; user; address; security
	3	智能合约安全与漏洞检测	vulnerability; smartcontract; security; analysis; detect
	9	开发者教育与开源协议资源	openbook; guide; solana; cancel; repository
	12	AI 驱动的去中心化建设	AI; data; infrastructure; decentralize; selfaware

2022 年的主题强度结构发生变化，“DApp 开发与 DeFi”和“智能合约应用与租赁”主题强度最高。随着多链架构的拓展和 Layer 2 扩容方案的进一步发展，开发者开始关注构建更具交互性与复杂逻辑的去中心化应用。项目“foundry-rs/foundry”是基于 Rust 编写的以太坊应用开发工具包，凭借其高效的编译和测试能力、强大的运行能力，成为当年最受关注的开发框架之一。此外，“alejoacosta74/blockchain-bike-rental”项目基于区块链开发自行车租赁系统，通过智能合约实现了协议签署、支付和资产归还的自动化处理，在一定程度上降低了人为干预的强度并提升了信任度，体现了智能合约在实体资产租赁中的应用潜力。

中国知网　https://www.cnki.net

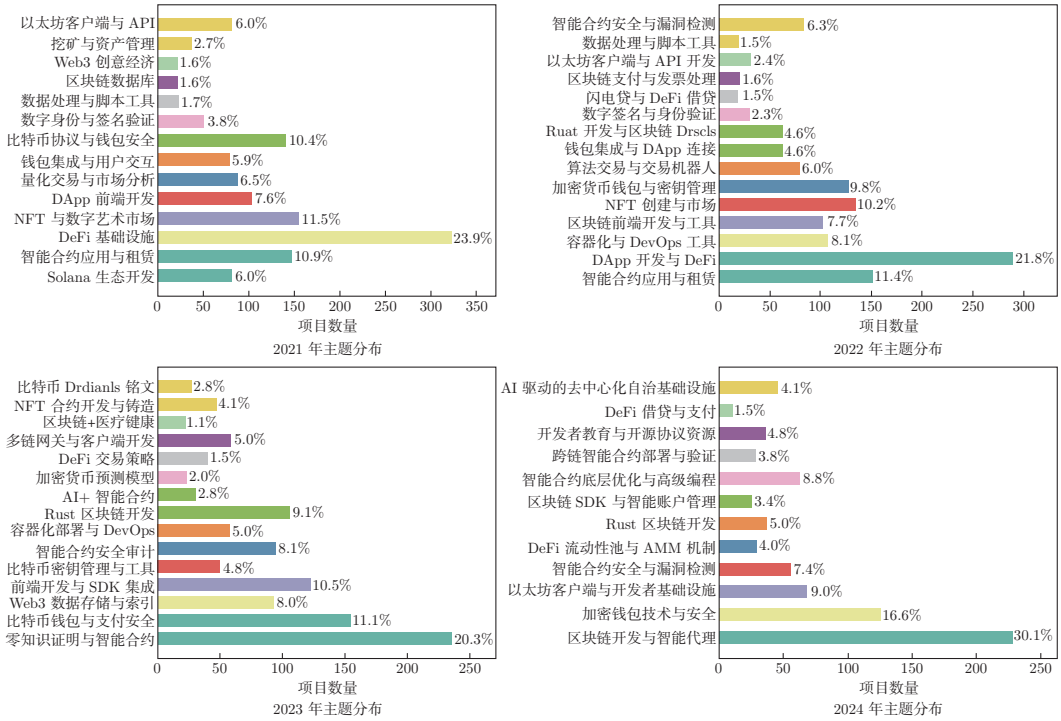


图 4 2021—2024 年主题强度

Figure 4 Topic intensity (2021—2024)

至 2023 年，零知识证明技术因其能够在不泄露原始数据的情况下完成验证而受到开发者广泛关注，“零知识证明与智能合约”主题占比提升。例如，GitHub 项目“matter-labs/foundry-zksync”扩展了 Foundry 在以太坊应用开发的能力，并允许在 ZKsync 上编译、部署、测试和交互智能合约。而“succinctlabs/sp1”提供了一个零知识虚拟机，支持开发者使用 Rust 语言编写可验证程序，并将证明提交至链上进行校验。这代表了零知识证明技术为进一步提升智能合约可扩展性以及隐私性提供了重要技术支撑，吸引了广大投资者和开发者的关注。

对于 2024 年，强度最高的是主题“区块链开发与智能代理”，这一特点与近年来人工智能技术的快速发展及其与区块链的融合发展密切相关。“Fetch.ai”结合区块链与人工智能技术构建了一个自治经济代理架构（autonomous economic agent, AEA），该架构被广泛应用于物流、金融、能源等多领域，为实现自动化、高效安全的经济交互提供了重要基础。人工智能的发展为区块链技术革新带来了更多可能性，如何将区块链和 AI 结合起来以提升性能和效率并满足更多的应用场景和需求，是该年度开发社区重点关注的议题。

3.1.2 技术影响力与再创活跃度

与主题强度分析不同，技术影响力将从微观的角度量化项目的实际受认可程度，再创活跃度则反映项目的二次开发潜力，即高比例意味着开发者不仅关注项目，还主动参与修改和扩展项目。具体结果如图 5 所示。

2021 年，加密货币市场在资本的助推下迎来爆发，市值不断突破。对于开发者和投资者而言，其可以通过建立算法模型来识别潜在交易机会，并可融合更多先进技术优化交易算法策略以提升量化交易结果。根据本文技术影响力指标结果，该年度技术影响力最高的主题

中国知网 https://www.cnki.net

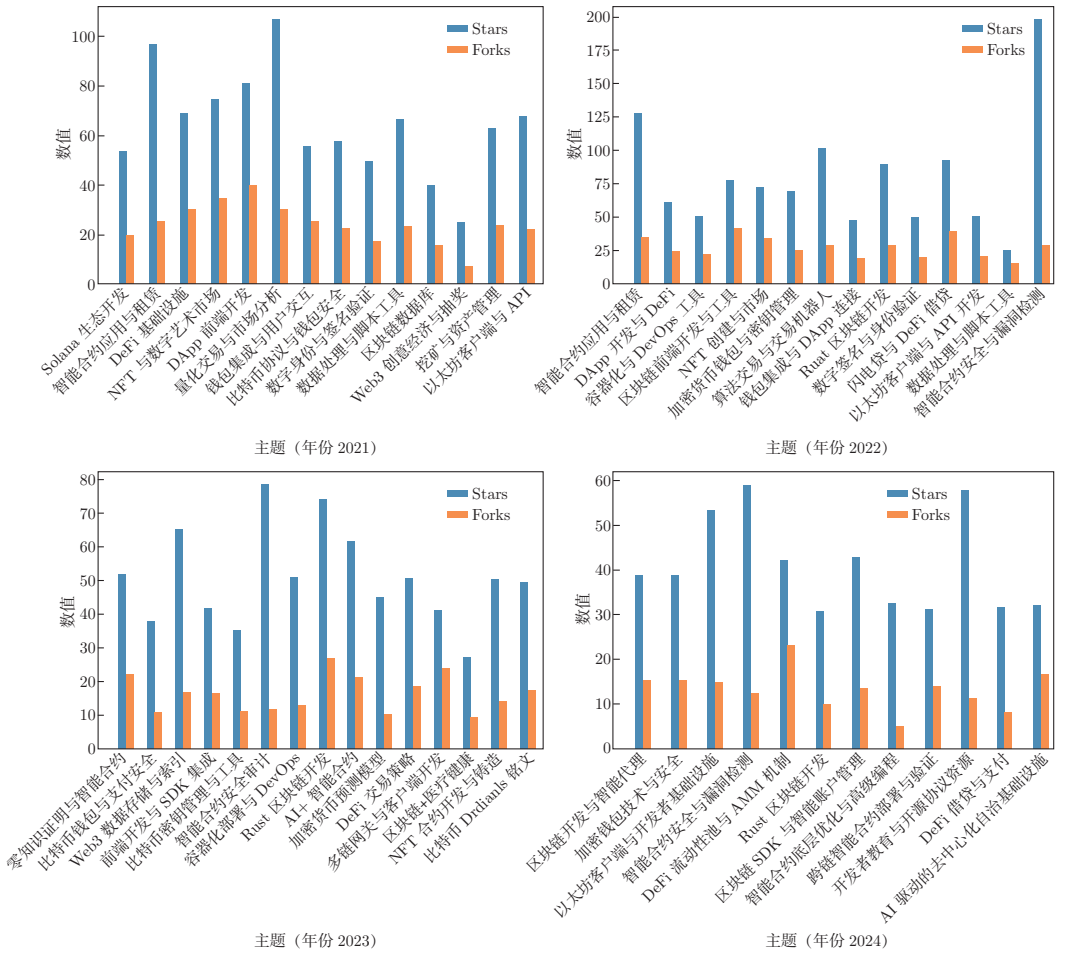


图 5　2021—2024 年 GitHub 技术影响力与再创活跃度

Figure 5　GitHub technological influence and secondary development activity (2021—2024)

是“量化交易与市场分析”，与该年度市场兴盛的特征十分吻合。与此同时，主题“DApp 前端开发”的再创活跃度最高，这表明开发者在积极完善区块链基础设施和底层协议的同时，亦重视程序和软件的功能设计和交互体验等。

2022—2024 年，技术影响力最高的主题主要都是围绕“智能合约安全”展开，体现了安全性在区块链行业中的重要地位。2022 年的开发项目“crytic/medusa”创建了一个跨平台的智能合约模糊测试工具，该工具具备多线程并行测试并且能够更灵活地实现用户输入等能力，在检测合约中的漏洞和逻辑错误方面做出了新的贡献。至 2024 年，随着智能代理和自动化决策的快速发展，新型攻击风险层出不穷，这也就要求面对开发者和相关平台出台更多新的安全标准。“OWASP/www-project-smart-contract-security-verification-standard”针对设计、构建和测试智能合约提供了相应的安全标准，为指导智能合约开发者和开发团队提供了相应的安全实践综合指南，以此能够更好地应对智能合约面临的安全挑战。在再创活跃度方面，2022 年主题“数据处理与脚本工具”热度最高，这表明了开发者会根据不同场景的不同需求，在工具链方面进行二次应用与扩展，与现实开发情况十分吻合。

总的来说，主题强度代表整个区块链开源社区整体的发展热度，而技术影响力和再创活

中国知网　https://www.cnki.net

跃度这两项指标则从更微观的角度展现个体开发者的实际关注情况。其中，技术影响力高的主题多与安全和交易相关，再创活跃度高的主题主要集中于工具链方面。

3.2 主题演化分析

如 1.5 节所述，本文将 2021—2024 年划分为 4 个时间窗口，通过主题相似度计算和桑基图可视化分析主题演化特征和结构，具体主题演化路径如图 6 所示。重点把演化主题归纳为 3 类，包括延续型主题、分裂与融合型主题、新兴与衰退型主题。

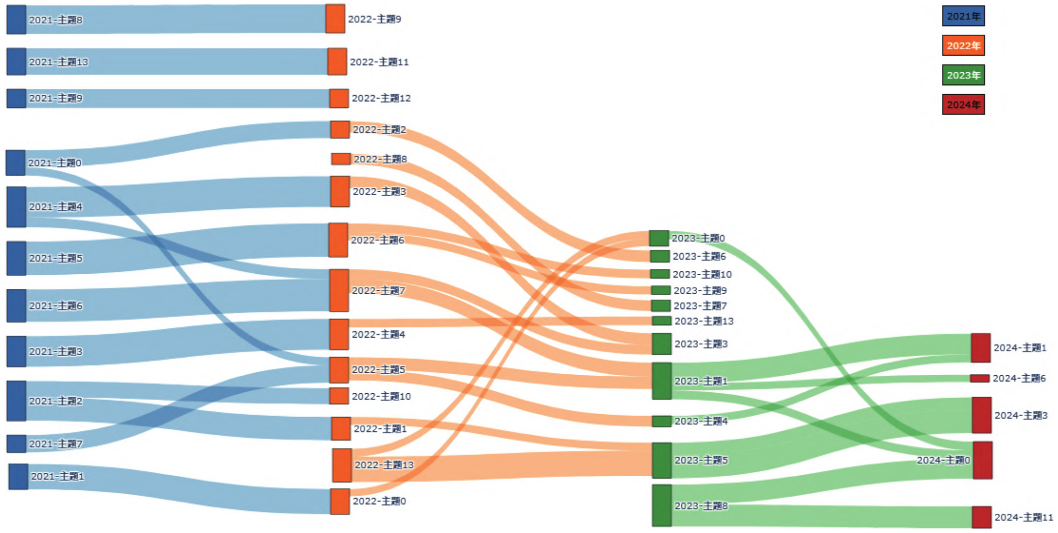


图 6 2021—2024 年主题演化路径

Figure 6 Topic evolution path (2021—2024)

延续型主题是指该主题具有较强的技术延展性和发展持续性，要求相邻年份主题相似度不低于 0.5。技术主题“智能合约”就有着很强的代表性：2021 年初始主题为“智能合约与租赁”，到 2022 年依旧能识别出该同名主题，至 2023 年智能合约相关主题被识别为“零知识证明与智能合约”，揭示了智能合约与隐私保护技术的融合发展，到 2024 年该方向演化为主题“区块链开发与智能代理”，代表了在人工智能相关技术加持下智能合约智能化发展的新特点。此外，与加密货币交易相关的主题也有着一定的延续性：2021 年的主题“量化交易与市场分析”在 2022 年演化为主题“算法交易与交易机器人”，交易者和开发者不断更新交易方法和交易策略以期通过先进技术优化交易结果。

在基础设施完善后，推进技术向应用层创新通常是开发者追寻的目标，本文主题的实际演化规律也恰好印证了这一观点。在主题分化和融合方面，2021 年主题“DeFi 基础设施”在 2022 年分裂为主题“DApp 与 DeFi”和“闪电贷与 DeFi 借贷”。在 2022 年 DeFi 领域发生了一些危机，Luna 和 Terra 稳定币下降以及 FTX 大规模欺诈加剧了 DeFi 相关指标的下降。在这一情况下，2022 年加密货币市场整体偏向低迷，但实际上 DeFi 协议本身并未受到直接影响，反而因为此次危机更凸显了透明借贷的优势，这也解释了为何 2022 年在区块链开源社区中与 DeFi 相关的技术主题识别中会演化为“闪电贷与 DeFi 借贷”。

对于新兴主题和衰退主题，技术主题演化主要呈现出如下特征：新兴主题多集中于人工智能相关领域，而衰退主题则涉及早期区块链工具链和特定应用方面。在 AI 技术发展的过程中，人们对透明度、数据完整性以及合规性的需求越来越高，因此开发者以期通过利用区块链

中国知网 https://www.cnki.net

技术独有优势来确保 AI 运作的隐私安全和合规信任。“AI 驱动的去中心化建设”主题应运而生，该主题在之前年份并无前驱主题，因此根据本文定义其可被认定为新兴主题。若部分早期主题逐渐衰退或仅短暂在某一年份出现则被定义为衰退主题。以主题“挖矿与资产管理”为例，其虽在 2021 年具有较高的主题强度，但随着后续相关国家政策的出台以及挖矿工具的日益成熟，其在开源社区的热度逐渐下降。此外，2023 年出现的多个具有时效性的主题在 2024 年并未延续，如“区块链+医疗健康”与“Ordinals 铭文”。这种阶段性的主题衰退并不直接代表技术淘汰或者应用创新失败，往往与年度热点、政策导向及技术成熟度密切相关。

总的来说，区块链技术主题演化特点可概括为以下方面：与 DeFi 基础设施、智能合约、隐私安全相关的主题技术演化路径清晰，延续性强；随着零知识证明、安全审计、多链互操作等技术的发展，区块链技术呈现出专业化和多样化的发展趋势；AI 与区块链的融合日益紧密，区块链与 AI 技术协同发展的格局正在形成。

4　结　语

本文以 2021—2024 年 GitHub 平台区块链开源项目为研究对象进行主题识别，丰富了区块链技术主题识别的数据源，并验证了“LLM+BERTopic”方法在非结构化开源文本中的适用性，为技术演化研究提供了新的方法论范式。此外，综合主题强度、技术影响力与再创活跃度 3 项指标对区块链技术主题进行主题演化分析，最终得出以下结论：基于 GitHub 区块链开源项目识别出的技术主题丰富多样，涵盖核心技术开发、金融交易、艺术融合、赋能医疗等多方面，展现了区块链技术从底层协议建设向应用层面及跨领域融合发展的特点；此外，不同主题在不同时期的关注度与社区参与度存在显著差异，开发社区的整体资源投入和关注重点与个体开发者的关注也存在不同；对于主题演化分析结果，智能合约、DeFi 等核心主题展现出清晰的延续性特点，一些早期综合性主题在后期不断细化，逐渐发展为适配不同场景和不同需求的技术主题；“AI+智能合约”和“AI 驱动的去中心化建设”等新兴主题的出现，标志着区块链技术发展进入智能化新阶段；部分早期工具链或特定应用主题随着技术栈的成熟或热点转移而逐渐衰退。但本文也存在一定的不足：在数据选择上，仅选择了 GitHub 平台上的数据，未能涵盖其他开源平台的数据，后续可进一步丰富技术数据来源并整合多源数据进行区块链主题对比分析研究；此外，本文主要基于文本相似度进行主题演化分析，对于主题间复杂的技术逻辑关联、因果关系的挖掘尚显不足；最后，基于 LLM 在主题挖掘过程中会出现的大模型幻觉等问题，后续研究中可进一步构建特定的 LLM 微调以提高输出准确性。

参考文献:

[1] Nakamoto S. Bitcoin: a peer-to-peer electronic cash system [EB/OL]. [2026-02-23]. https://bitcoin.org/bitcoin.pdf, 2008.

[2] 代闯闯, 栾海晶, 杨雪莹, 等. 区块链技术研究综述 [J]. 计算机科学, 2021, 48(增刊 2): 500-508.
Dai C C, Luan H J, Yang X Y, et al. A review of blockchain technology research [J]. Computer Science, 2021, 48(Suppl.2): 500-508 (in Chinese).

[3] Chen J E, Bao F, Li C, et al. The application and ethics of artificial intelligence in blockchain: a bibliometric-content analysis [J]. Journal of Global Information Management, 2023, 31(7): 1-32.

[4] Kalliamvakou E, Gousios G, Blincoe K, et al. An in-depth study of the promises and perils of mining GitHub [J]. Empirical Software Engineering, 2016, 21(5): 2035-2071.

[5] Park Y, Lim S, Gu C, et al. Forecasting topic trends of blockchain utilizing topic modeling and deep learning-based time-series prediction on different document types [J]. Journal of Informetrics, 2025, 19(2): 101639.

[6] Mafrur R. Blockchain data analytics: review and challenges [PP/OL]. V1. (2025-03-12) [2026-02-23]. https://doi.org/10.48550/arXiv.2503.09165.

中国知网　https://www.cnki.net

[7] Vaccargiu M, Aufiero S, Bartolucci S, et al. Sustainability in blockchain development: a BERT-based analysis of Ethereum developer discussions [C]//28th International Conference on Evaluation and Assessment in Software Engineering, 2024: 381-386.

[8] Ibba G, Vaccargiu M. Analysis of users' most discussed topics and trends on blockchain technologies and smart contracts [C]//2023 IEEE International Conference on Software Analysis, Evolution and Reengineering, 2023: 865-873.

[9] 汪园, 王学东, 李金鑫. 基于文献计量的我国区块链研究的知识网络与结构分析 [J]. 现代情报, 2018, 38(1): 147-153.
Wang Y, Wang X D, Li J X. Knowledge network and structure analysis of blockchain research in China based on bibliometrics [J]. Journal of Modern Information, 2018, 38(1): 147-153. (in Chinese).

[10] 罗棋, 闵超, 颜嘉麒, 等. 国际区块链研究主题挖掘及演化分析 [J]. 现代情报, 2021, 41(9): 157-166.
Luo Q, Min C, Yan J Q, et al. Mining and evolution analysis of international blockchain research topics [J]. Journal of Modern Information, 2021, 41(9): 157-166. (in Chinese).

[11] Grootendorst M. BERTopic: neural topic modeling with a class-based TF-IDF procedure [PP/OL]. V1 (2022-03-11) [2026-02-23]. https://doi.org/10.48550/arXiv.2203.05794.

[12] Abdelrazek A, Eid Y, Gawish E, et al. Topic modeling algorithms and applications: a survey [J]. Information Systems, 2023, 112: 102131.

[13] 温晓波, 姚长青, 高影繁. 大语言模型增强的科技文献主题识别 [J]. 情报理论与实践, 2025, 48(9): 185-193.
Wen X B, Yao C Q, Gao Y F. Topic identification of scientific and technological literature enhanced by large language models [J]. Information Studies: Theory & Application, 2025, 48 (9): 185-193. (in Chinese)

[14] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners [J]. Advances in Neural Information Processing Systems, 2020, 33: 1877-1901.

[15] Han S, Shin M, Park S, et al. Unified neural topic model via contrastive learning and term weighting [C]//17th Conference of the European Chapter of the Association for Computational Linguistics. 2023: 1802-1817.

[16] Yang X, Zhao H, Xu W, et al. Neural topic modeling with large language models in the loop [C]// 63rd Annual Meeting of the Association for Computational Linguistics, 2025: 1377-1401.

[17] 张凯, 杨敏纳, 隗玲. 融合 Finetuned-BERTopic 和大模型的技术主题识别方法研究 [J]. 情报理论与实践, 2025, 48(3): 189-198.
Zhang K, Yang M N, Wei L. Research on technology topic identification method integrating Finetuned-BERTopic and large model [J]. Information Studies: Theory & Application, 2025, 48 (3): 189-198. (in Chinese)

[18] Sharma A, Thung F, Kochhar P S, et al. Cataloging GitHub repositories [C]// 21st International Conference on Evaluation and Assessment in Software Engineering, 2017: 314-319.

[19] 李舟军, 范宇, 吴贤杰. 面向自然语言处理的预训练技术研究综述 [J]. 计算机科学, 2020, 47(3): 162-173.
Li Z J, Fan Y, Wu X J. A review of pre-training technologies for natural language processing [J]. Computer Science, 2020, 47 (3): 162-173. (in Chinese)

[20] Mcinnes L, Healy J, Astels S. HDBSCAN: hierarchical density based clustering [J]. Journal of Open Source Software, 2017, 2(11): 205.

[21] 蔡鑫, 靳军宝, 王政媛, 等. 融合主题语义与转移概率的"科学—技术" 主题演化路径识别研究 [J]. 情报理论与实践, 2026, 49(1): 138-149.
Cai X, Jin J B, Wang Z Y, et al. Research on identification of "science-technology" topic evolution path integrating topic semantics and transition probability [J]. Information Studies: Theory & Application, 2026, 49 (1): 138-149. (in Chinese)

[22] Zhang Y, Chen M, Liu L. A review on text mining [C]//2015 6th IEEE International Conference on Software Engineering and Service Science, 2015: 681-685.

[23] Reuter A, Khadka B, Thielmann A, et al. Gptopic: dynamic and interactive topic representations [PP/OL]. V1 (2024-03-06) [2026-02-23]. https://doi.org/10.48550/arXiv.2403.03628.

中国知网 https://www.cnki.net

[24] 许海云, 龚兵营, 杨俊浩, 等. 新兴研究主题识别方法研究进展与前瞻 [J]. 图书情报工作, 2025, 69(3): 135-150.
Xu H Y, Gong B Y, Yang J H, et al. Research progress and prospect of emerging research topic identification methods [J]. Library and Information Service, 2025, 69 (3): 135-150. (in Chinese)

[25] Github Documentation. Saving repositories with stars [EB/OL]. (2016-10-19) [2026-02-23]. https://help.github.com/articles/about-stars/.

[26] Bhatia A, Eghan E E, Grichi M, et al. Towards a change taxonomy for machine learning systems [PP/OL]. V1 (2022-03-21) [2026-02-23]. https://doi.org/10.48550/arXiv.2203.11365.

[27] 马海群, 崔文波, 张涛. 我国数据安全政策文本主题挖掘及其演化分析 [J]. 现代情报, 2024, 44(8): 28-38.
Ma H Q, Cui W B, Zhang T. Topic mining and evolution analysis of China's data security policy texts [J]. Journal of Modern Information, 2024, 44(8): 28-38. (in Chinese)

[28] 秦晓慧, 乐小虬. 基于 LDA 主题关联过滤的领域主题演化研究 [J]. 现代图书情报技术, 2015, (3): 18-25.
Qin X H, Le X Q. Research on domain topic evolution based on LDA topic correlation filtering [J]. New Technology of Library and Information Service, 2015 (3): 18-25. (in Chinese)

[29] Izadi M, Heydarnoori A, Gousios G. Topic recommendation for software repositories using multi-label classification algorithms [J]. Empirical Software Engineering, 2021, 26(5): 93.

(编辑：王　雪)

中国知网　https://www.cnki.net